

TESTING.md - Guide complet de test

Prerequisites

```
cd project-rag
cp .env.example .env
pip install -r requirements.txt
```

Flow 1 : Indexation du corpus

```
python scripts/ingest.py
```

Output attendu :

```
Chargement du corpus...
Corpus charge: 1461 documents
Indexation dans ChromaDB...
Indexation terminee: X chunks indexes
```

Flow 2 : API + Frontend

```
python -m uvicorn api.main:app --reload --port 8000
```

Puis ouvre <http://localhost:8000>

Tester les 4 approches depuis l'interface :

1. Selecteur Modele : **mistral-small-latest**
2. Selecteur Approche : **LLM seul** → Envoie, vérifie reponse sans source
3. Selecteur Approche : **RAG simple** → Envoie, vérifie sources cites
4. Selecteur Approche : **RAG+Reranking** → Envoie, vérifie qualite
5. Selecteur Approche : **Hybrid Search** → Envoie, verifie

Tester avec les questions :

- "What is the role of the AMF in 5G core network?"
- "What is network slicing?"
- "How does 5G NR differ from LTE?"

Flow 3 : Comparaison automatique (Models x Approches)

```
python scripts/run_comparaison.py 5    # 5 questions (rapide)
```

Output attendu :

```
Comparaison 3 modeles x 4 approches sur 5 questions

[mistral-small / LLM seul]... EM=1/5  F1=0.35  Temps=1.2s
[mistral-small / RAG simple]... EM=3/5  F1=0.65  Temps=3.0s
...

RESUME: MODELE x APPROCHE
Modele / Approche          EM      Prec.    Recall   F1      Temps
mistral-small / LLM seul    ...
mistral-small / RAG simple  ...
...
```

Flow 4 : Graphiques

```
python scripts/generer_graphiques.py
```

Genere dans [reports/graphiques/](#) :

- [f1_modele_approche.png](#)
- [temps_modele_approche.png](#)
- [heatmap_f1.png](#)
- [radar_modeles.png](#)
- [tableau_comparatif.png](#)

Flow 5 : Tests unitaires

```
python -m pytest tests/ -v
```

Flow 6 : Presentation

Ouvre [presentation/soutenance.html](#) dans un navigateur.

Navigation : clavier (fleches gauche/droite) ou boutons.

Flow 7 : Fine-tuning (Colab)

1. Va sur <https://colab.research.google.com/>
2. Upload [notebooks/fine_tuning_teleqna_colab.ipynb](#)

3. Runtime > Change runtime type > T4 GPU
4. Runtime > Run all
5. Upload `data/telecom_train.json` quand demande
6. Après entraînement (~1h), télécharge l'adapter LoRA
7. Décompresse dans `src/finetuning/telecom_lora_adapter/`

Verification rapide

```
# Verifier que tout est en place
python -c "
from src.llm_seul.pipeline import LLMSeulPipeline
from src.rag_simple.pipeline import RAGSimplePipeline
from src.reranking.pipeline import RAGRerankingPipeline
from src.hybrid_search.pipeline import HybridSearchPipeline
print('Tous les pipelines sont importables')
"
```